

## 实验 2. 隐马尔科夫模型实践

MG1733098, 周华平, zhp@smail.nju.edu.cn

2017 年 11 月 29 日

### 综述

隐马尔科夫模型 (hidden Markov model, HMM) 是可用于标注问题的统计学习模型, 描述由隐藏的马尔科夫链随机生成观测序列的过程, 属于生成模型。

本实验首先针对一个已经训练好的 HMM, 实现维特比算法, 通过动态规划的思想对模型进行推断; 其次, 针对参数未知的 HMM, 通过 Baum-Welch 算法对数据进行学习与训练, 其中我们需要实现 HMM 的前向和后向算法。

### 实验一.

维特比算法实际是用动态规划解隐马尔科夫模型预测问题, 即用动态规划求概率最大路径 (最优路径)。这时一条路径对应着一个状态序列。

根据动态规划原理, 最优路径具有这样的特性: 如果最优路径在时刻  $t$  通过节点  $i_t^*$ , 那么这一路径从节点  $i_t^*$  到终点  $i_T^*$  的部分路径, 对于从  $i_t^*$  到  $i_T^*$  的所有可能的部分路径来说, 必须是最优的。因为假如不是这样, 那么从  $i_t^*$  到  $i_T^*$  就有另一条更好的部分路径存在, 如果把它和从  $i_t^*$  到达  $i_T^*$  的部分路径连接起来, 就会形成一条比原来的路径更优的路径, 这是矛盾的。依据这一原理, 我们只需从时刻  $t = 1$  开始, 递推地计算在时刻  $t$  状态为  $i$  的各条部分路径的最大概率, 直至得到时刻  $t = T$  状态为  $i$  的各条路径的最大概率。时刻  $t = T$  的最大概率即为最优路径的概率  $P^*$ , 最优路径的终结点  $i_T^*$  也同时得到。之后, 为了找出最优路径的各个节点, 从终结点  $i_T^*$  开始, 由后向前逐步求得节点  $i_{T-1}^*, \dots, i_1^*$ , 得到最优路径  $I^* = (i_1^*, i_2^*, \dots, i_T^*)$ 。这就是维特比算法。

首先导入两个变量  $\delta$  和  $\psi$ 。定义在时刻  $t$  状态为  $i$  的所有单个路径  $(i_1, i_2, \dots, i_t)$  中概率最大值为

$$\delta_t(i) = \max_{i_1, i_2, \dots, i_{t-1}} P(i_t = i, i_{t-1}, \dots, i_1, o_t, \dots, o_1 | \lambda), \quad i = 1, 2, \dots, N$$

由定义可得变量  $\delta$  的递推公式:

$$\begin{aligned} \delta_{t+1}(i) &= \max_{i_1, i_2, \dots, i_t} P(i_{t+1} = i, i_t, \dots, i_1, o_{t+1}, \dots, o_1 | \lambda) \\ &= \max_{1 \leq j \leq N} [\delta_t(j) a_{ji}] b_i(o_{t+1}), \quad i = 1, 2, \dots, N; t = 1, 2, \dots, T-1 \end{aligned}$$

定义在时刻  $t$  状态为  $i$  的所有单个路径  $(i_1, i_2, \dots, i_{t-1}, i)$  中概率最大的路径的第  $t-1$  个节点为

$$\psi_t(i) = \operatorname{argmax}_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}], \quad i = 1, 2, \dots, N$$

## 维特比算法

输入：模型  $\lambda = (A, B, \pi)$  和观测  $O = (o_1, o_2, \dots, o_T)$

输出：最优路径  $I^* = (i_1^*, i_2^*, \dots, i_T^*)$

(1) 初始化

$$\begin{aligned} \delta_1(i) &= \pi_i b_i(o_1), \quad i = 1, 2, \dots, N \\ \psi_1(i) &= 0, \quad i = 1, 2, \dots, N \end{aligned}$$

(2) 递推。对  $t = 2, 3, \dots, T$

$$\begin{aligned} \delta_t(i) &= \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}] b_i(o_t), \quad i = 1, 2, \dots, N \\ \psi_t(i) &= \operatorname{argmax}_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}], \quad i = 1, 2, \dots, N \end{aligned}$$

(3) 终止

$$\begin{aligned} P^* &= \max_{1 \leq i \leq N} \delta_T(i) \\ i_T^* &= \operatorname{argmax}_{1 \leq i \leq N} [\delta_T(i)] \end{aligned}$$

(4) 最优路径回溯。对  $t = T-1, T-2, \dots, 1$

$$i_t^* = \psi_{t+1}(i_{t+1}^*)$$

求得最优路径  $I^* = (i_1^*, i_2^*, \dots, i_T^*)$ 。

## 实验二.

给定隐马尔科夫模型  $\lambda$ ，定义到时刻  $t$  部分观测序列为  $o_1, o_2, \dots, o_t$  且状态为  $q_i$  的概率为前向概率，记作

$$\alpha_t(i) = P(o_1, o_2, \dots, o_t, i_t = q_i | \lambda)$$

可以递推地求得前向概率  $\alpha_t(i)$  及观测序列概率  $P(O|\lambda)$ 。

## 观测序列概率的前向算法

输入：隐马尔科夫模型  $\lambda$ ，观测序列  $O$

输出：观测序列概率  $P(O|\lambda)$

(1) 初值

$$\alpha_1(i) = \pi_i b_i(o_1), \quad i = 1, 2, \dots, N$$

(2) 递推。对  $t = 1, 2, \dots, T - 1$

$$\alpha_{t+1}(i) = \left[ \sum_{j=1}^N \alpha_t(j) a_{ji} \right] b_i(o_{t+1}), \quad i = 1, 2, \dots, N$$

(3) 终止

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$$

前向算法中，步骤 (1) 初始化前向概率，是初始时刻的状态  $i_1 = q_i$  和观测  $o_1$  的联合概率。步骤 (2) 是前向概率的递推公式，计算到时刻  $t + 1$  部分观测序列为  $o_1, o_2, \dots, o_t, o_{t+1}$  且在时刻  $t + 1$  处于状态  $q_i$  的前向概率。步骤 (3) 给出  $P(O|\lambda)$  的计算公式，因为

$$\alpha_T(i) = P(o_1, o_2, \dots, o_t, i_T = q_i | \lambda)$$

所以

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$$

### 实验三.

给定隐马尔科夫模型  $\lambda$ ，定义在时刻  $t$  状态为  $q_i$  的条件下，从  $t + 1$  到  $T$  的部分观测序列为  $o_{t+1}, o_{t+2}, \dots, o_T$  的概率为后向概率，记作

$$\beta_t(i) = P(o_{t+1}, o_{t+2}, \dots, o_T | i_t = q_i, \lambda)$$

可以用递推的方法求得后向概率  $\beta_t(i)$  及观测序列概率  $P(O|\lambda)$ 。

#### 观测序列概率的后向算法

输入：隐马尔科夫模型  $\lambda$ ，观测序列  $O$

输出：观测序列概率  $P(O|\lambda)$

(1) 初值

$$\beta_T(i) = 1, \quad i = 1, 2, \dots, N$$

(2) 递推。对  $t = T - 1, T - 2, \dots, 1$

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad i = 1, 2, \dots, N$$

(3) 终止

$$P(O|\lambda) = \sum_{i=1}^N \pi_i b_i(o_1) \beta_1(i)$$

步骤 (1) 初始化后向概率，对最终时刻的所有状态  $q_i$  规定  $\beta_T(i) = 1$ 。步骤 (2) 是后巷概率的递推公式。为了计算在时刻  $t$  状态为  $q_i$  条件下时刻  $t + 1$  之后的观测序列为  $o_{t+1}, o_{t+2}, \dots, o_T$  的后向概率  $\beta_t(i)$ ，只需考虑在时刻  $t + 1$  所有可能的  $N$  个状态  $q_j$  的转移概率，以及在此状态下的观测  $o_{t+1}$  的观测概率，然后考虑状态  $q_j$  之后的观测序列的后向概率。步骤 (3) 求  $P(O|\lambda)$  的思路与步骤 (2) 一致，只是初始概率  $\pi_i$  代替转移概率。

## 参考文献

- [1] 周志华. 机器学习. 清华大学出版社, 2016.
- [2] 李航 et al. 统计学习方法. 清华大学出版社, 北京, 2012.